

Raport wykonany przez:
Lab grupa, ID, Nazwisko, Imię

7, 71555, Banasiewicz, Aleksandra
7, 72791, Ciarka, Natalia
7, 73134, Gawda, Agata
7, 73185, Kęska, Karolina
7, 72525, Kołodziejczyk, Milena

P3_7_Motyłki

Przewidzenie liczebności motyli w Kalifornii w 2025 roku (forecast) na podstawie danych monitoringowych z 2000-2016?

1. Cel projektu

Celem projektu jest przewidywanie liczebności motyli (count) na podstawie historycznych danych ekologicznych. Jest to problem regresji w uczeniu maszynowym (supervised machine learning regression).

Model ma:

- prognozować przyszłą liczebność motyli,
- analizować sezonowość występowania gatunków,
- identyfikować trendy wzrostu i spadku populacji,

2. Źródło i opis danych

Dane wykorzystane w projekcie pochodzą z ogólnodostępnych zbiorów dotyczących monitoringu motyli w Kalifornii. Zbiór danych zawiera informacje o liczbie zaobserwowanych motyli w różnych latach oraz dla różnych gatunków.

Dane mają charakter obserwacyjny i zostały zebrane w ramach badań terenowych.

Link do danych: [Western Butterflies Dataset](#)

3. Definicja problemu

Dane wejściowe (input)

Model otrzymuje następujące dane:

- site_name — lokalizacja obserwacji,
- genus_species — nazwa gatunku motyla,
- year — rok obserwacji,
- month — miesiąc obserwacji,
- day — dzień roku, w którym odbyła się obserwacja.

Dane wyjściowe (output)

Model przewiduje:

- count — prognozowaną liczebność motyli.

4. Wybór modelu

Nazwa modelu: LightGBM

Typ modelu:

- Gradient Boosted Decision Trees (GBDT),
- model regresyjny,
- uczenie nadzorowane (supervised learning).

Jest to model oparty na zespołach drzew decyzyjnych zoptymalizowany pod duże dane tabelaryczne.

Wymagania postawione podczas wyboru modelu:

Zbiór danych zawiera około:

- 547 846 rekordów.

Potrzebny był model:

- szybki,
- wydajny pamięciowo,
- możliwy do uruchomienia na zwykłym komputerze.

Powody wyboru modelu:

Dane mają charakter:

- tabelaryczny,
- sezonowy,
- nieliniowy,
- zawierają zmienne kategoryczne (site_name, genus_species).

LightGBM bardzo dobrze radzi sobie z:

- dużymi zbiorami danych,
- danymi tabelarycznymi,
- zależnościami nieliniowymi,
- analizą sezonowości,
- zmiennymi kategorycznymi.

Model potrafi uczyć się:

- zależności między gatunkami,
- wpływu lokalizacji,
- zmian sezonowych,
- zmian liczebności w czasie.

5. Metodologia

5.1 Przygotowanie danych

Dane zostały wstępnie oczyszczone i przygotowane do analizy.

Wykonano:

- konwersję dat,
- usunięcie brakujących wartości,
- utworzenie cechy day_of_year,
- przygotowanie zmiennych kategorycznych.

5.2 Podział danych

Dane zostały podzielone czasowo:

- dane treningowe — przed 2019 rokiem,
- dane testowe — od 2019 roku.

Pozwoliło to zasymulować rzeczywisty forecasting przyszłych danych.

5.3 Trenowanie modelu

Model został wytrenowany przy użyciu:

- danych lokalizacyjnych,
- gatunków motyli,
- cech czasowych.

Do ewaluacji wykorzystano metrykę MAE (Mean Absolute Error).

6. Ewaluacja modelu

Metoda oceny

Model był oceniany za pomocą:

- MAE (Mean Absolute Error),
- podziału czasowego train/test,
- analizy trendów,
- oceny sensowności wyników.

Modele wybrane do testów:

- CatBoost,
- XGBoost,
- LightGBM.

Wyniki modeli

Model	MAE
CatBoost	$\approx 1,57$
LightGBM	$\approx 1,22$
XGBoost	-

Wybrano model LightGBM, ponieważ osiągnął najlepszą dokładność predykcji.

Uzyskany wynik

LightGBM MAE: 1.2179243228430638

Oznacza to, że model średnio mylił się o około 1.22 osobnika podczas przewidywania liczebności motyli.

7. Analiza i interpretacja wyników

Analiza sezonowości

Model poprawnie wykrył sezonowość występowania motyli.

Najwyższe przewidywane wartości liczebności pojawiały się w miesiącach:

- wiosennych,
- letnich,
- wczesnojesiennych.

Najniższa aktywność była obserwowana zimą, co jest zgodne z rzeczywistymi zależnościami biologicznymi.

Wyniki sugerują, że model nauczył się:

- wpływu sezonu na aktywność motyli,
- zależności pomiędzy miesiącem a liczebnością populacji.

```
#Aktywność motyli w 2025 rozdzielona na miesiące, brak ograniczenia na wartości minusowe
#0 = brak aktywności
#wartości ujemne = „bardzo niska aktywność”
#wartości dodatnie = sezon wysokiej aktywności

time_trend = future.groupby("month")["predicted_count"].mean()

print(time_trend)
```

```
month
1    -0.017518
2    -0.064392
3     0.227345
4     1.064438
5     0.635037
6     0.863614
7     0.947940
8     0.920606
9     0.679259
10    1.355337
11    0.146141
12   -0.293612
```

Analiza gatunków

Na podstawie prognoz modelu możliwe było określenie gatunków o najwyższej przewidywanej liczebności.

Najczęściej występujące gatunki według modelu:

```
genus_species
Pieris rapae          17701.820548
Hylephila phyleus    6466.992407
Pyrgus communis      5735.674294
Junonia coenia       5205.183191
Battus philenor      5011.384651
Brephidium exile     4035.772054
Colias eurytheme     3966.251604
Vanessa cardui       2203.488986
Atalopedes campestris 2166.554077
Coenonympha tullia californica 1991.145874
```

Przeprowadzono również analizę trendów populacyjnych, która pozwoliła określić:

- gatunki wykazujące trend wzrostowy,
- gatunki o malejącej liczebności.

```
#Gatunki zwiększające swoją liczebność w czasie
#slope > 0 => gatunek się zwiększa, bardziej widoczny w czasie
trend_df.sort_values("trend_slope", ascending=False).head(10)
```

	species	trend_slope
62	Hylephila phyleus	0.225138
38	Erynnis tristis	0.093945
48	Everes comyntas	0.067413
1	Agraulis vanillae	0.038388
100	Papilio rutulus	0.033355
120	Poanes melane	0.031040
69	Limenitis lorquini	0.025891
94	Ochlodes sylvanoides	0.023435
68	Lerodea eufala	0.005552
141	Satyrion sylvinus	0.004089

```
#Gatunki zanikające swoją liczebność w czasie
#slope < 0 => gatunek zanika, możliwość zagrożenia/wyginiecia
trend_df.sort_values("trend_slope").head(10)
```

	species	trend_slope
13	Brephidium exile	-3.919026
160	Vanessa cardui	-3.634146
114	Pieris rapae	-0.562871
11	Battus philenor	-0.271411
27	Colias eurytheme	-0.169385
121	Polites sabuleti sabuleti	-0.161014
66	Junonia coenia	-0.140107
9	Atalopedes campestris	-0.068764
49	Glaucopsyche lygdamus	-0.065600
153	Strymon melinus	-0.064323


Interpretacja trendów

Dodatni trend oznaczał:

- wzrost średniej liczebności gatunku w kolejnych latach,
- większą aktywność lub częstsze obserwacje.

Ujemny trend wskazywał:

- potencjalny spadek populacji,
- rzadsze występowanie gatunku,
- możliwość zmian środowiskowych wpływających na populację.



Ograniczenia interpretacji

Należy uwzględnić, że:

- model opiera się wyłącznie na danych historycznych,
- nie uwzględnia czynników środowiskowych (np. temperatury, opadów, zmian klimatu),
- przewidywania nie są dokładnym odwzorowaniem rzeczywistej liczby motyli,
- wyniki należy interpretować jako prognozy modelowe, a nie dokładne dane biologiczne.

Pomimo tych ograniczeń model pozwolił uzyskać wartościowe informacje dotyczące:

- sezonowości,
- trendów populacyjnych,
- zmian liczebności gatunków,
- prognoz ekologicznych.

8. Ograniczenia projektu i wymagania sprzętowe

Ograniczenia modelu

Najważniejsze ograniczenia:

- szum w danych ekologicznych,
- brak danych środowiskowych (np. temperatura, opady),
- nierównomierna liczba obserwacji dla różnych gatunków,
- trudność przewidywania rzadkich gatunków.

Model:

- może czasami generować wartości ujemne,
- nie modeluje biologicznych zależności przyczynowych,
- silnie zależy od jakości danych historycznych.

Dodatkowo:

- model nie jest jeszcze architekturą Transformer,
- stanowi etap pośredni przed fine-tuningiem modeli Transformerowych.

Ograniczenia sprzętowe

Uwzględniono:

- wielkość zbioru danych (~548 tys. rekordów),
- pamięć RAM,
- czas treningu,
- wydajność CPU.

9. Link do repozytorium GitHub

Repozytorium projektu znajduje się pod adresem:

[Repozytorium GitHub projektu](#)

10. Podział pracy / wkład członków grupy

Projekt został wykonany wspólnie przez członków grupy.

Zakres prac obejmował:

- weryfikację projektu,
- wybór modelu,
- pracę nad programem,
- wykonanie analizy danych,
- przygotowanie wizualizacji,
- opracowanie raportu końcowego.

Każdy członek grupy uczestniczył w realizacji projektu w równym stopniu.