

Raport wykonany przez:
Lab grupa, ID, Nazwisko, Imię

7, 71555, Banasiewicz, Aleksandra
7, 72791, Ciarka, Natalia
7, 73134, Gawda, Agata
7, 73185, Kęska, Karolina
7, 72525, Kołodziejczyk, Milena

P4_7_Motyłki

Klasyfikacja trendu liczebności motyli w Kalifornii w 2025 roku na podstawie danych monitoringowych z 2000-2016 z wykorzystaniem modelu DistilBERT

1. Cel projektu

Celem projektu było przygotowanie prostego modelu klasyfikacyjnego, który na podstawie danych dotyczących liczebności gatunków motyli przewiduje kierunek zmiany populacji w latach 2000–2016. Model miał przypisywać każdy gatunek do jednej z trzech klas:

- 0 — decreasing, czyli spadek liczebności,
- 1 — stable, czyli względnie stabilna liczebność,
- 2 — increasing, czyli wzrost liczebności.

W projekcie wykorzystano Model Hugging Face: `distilbert-base-uncased`, który został dostosowany do zadania klasyfikacji tekstu.

2. Źródło i opis danych

Dane wykorzystane w projekcie pochodzą z ogólnodostępnych zbiorów dotyczących monitoringu motyli w Kalifornii. Zbiór danych zawiera informacje o liczbie zaobserwowanych motyli w różnych latach oraz dla różnych gatunków.

Dane mają charakter obserwacyjny i zostały zebrane w ramach badań terenowych.

Link do danych: [Western Butterflies Dataset](#)

3. Definicja problemu

Dane wejściowe (input)

Model otrzymuje następujące dane:

- `site_name` — miejsce obserwacji,
- `visit_date` — data obserwacji,
- `genus_species` — nazwa gatunku,
- `pa` — informacja o obecności lub nieobecności gatunku,
- `count` — liczba zaobserwowanych osobników,
- `year` — rok obserwacji,
- `month` — miesiąc,
- `day` — dzień roku.

Do dalszej analizy wykorzystano dane z lat 2000–2016. Następnie zsumowano liczebność każdego gatunku w poszczególnych latach. Dla każdego gatunku wybrano liczebność z roku 2000 oraz z roku 2016.

4. Wybór modelu

W projekcie wykorzystano model DistilBERT dostępny w bibliotece Hugging Face Transformers. DistilBERT jest lżejszą wersją modelu BERT, zoptymalizowaną pod względem szybkości działania i mniejszych wymagań obliczeniowych.

Model został wybrany, ponieważ:

- umożliwia fine-tuning dla zadań klasyfikacji tekstu,
- dobrze radzi sobie z analizą krótkich opisów tekstowych,
- posiada mniejsze wymagania sprzętowe niż pełny model BERT,
- pozwala przeprowadzić trening na standardowym komputerze bez konieczności użycia zaawansowanego GPU.

Zastosowanie DistilBERT miało charakter eksperymentalny i edukacyjny, pokazując możliwość wykorzystania modeli Transformer do analizy trendów ekologicznych.

5. Przygotowanie danych

Przed rozpoczęciem treningu dane tekstowe zostały poddane tokenizacji przy użyciu tokenizera DistilBERT. Proces tokenizacji polegał na zamianie tekstu na sekwencje tokenów rozumiane przez model Transformer.

Teksty zostały automatycznie:

- podzielone na tokeny,
- zamienione na identyfikatory liczbowe,
- uzupełnione do jednakowej długości (padding),
- przycięte do maksymalnej długości wejścia (truncation).

Dla każdego gatunku obliczono procentową zmianę liczebności między rokiem 2000 a 2016 według wzoru:

$$((count_{2016} - count_{2000}) / count_{2000}) * 100$$

Jeżeli liczebność w roku 2000 wynosiła 0, wartość zmiany procentowej ustawiono na 0, aby uniknąć dzielenia przez zero.

Na podstawie procentowej zmiany utworzono etykiety klas:

- jeśli zmiana była większa niż 10%, gatunek otrzymywał etykietę 2, czyli increasing,
- jeśli zmiana była mniejsza niż -10%, gatunek otrzymywał etykietę 0, czyli decreasing,
- jeśli zmiana mieściła się w zakresie od -10% do 10%, gatunek otrzymywał etykietę 1, czyli stable.

Następnie dane liczbowe zostały zamienione na tekst, ponieważ model DistilBERT przyjmuje tekst jako dane wejściowe. Przykładowy tekst wejściowy wyglądał następująco:

- Species: Adelpha bredowii californica.
- Count in 2000: 5.
- Count in 2016: 12.
- Percentage change: 140.00%.

Ostatecznie przygotowany zbiór danych zawierał dwie kolumny:

- text — opis gatunku i zmiany liczebności,
- label — klasa trendu populacji.

6. Rozkład klas

Po przygotowaniu danych uzyskano następujący rozkład klas:

Klasa	Znaczenie	Liczba przykładów
0	decreasing	38
1	stable	101
2	increasing	24

Zbiór danych był niezbalansowany. Najwięcej przykładów należało do klasy stable, natomiast najmniej do klasy increasing. Jest to ważne, ponieważ niezbalansowany zbiór może powodować, że model lepiej uczy się klas częściej występujących, a gorzej radzi sobie z klasami rzadszymi.

7. Model i trening

W projekcie wykorzystano model DistilBERT głównie jako demonstrację procesu fine-tuningu modelu Transformer dla zadania klasyfikacji. Dane ekologiczne mają charakter liczbowy i tabelaryczny, dlatego zastosowanie modelu językowego wymagało wcześniejszego przekształcenia danych do postaci tekstowej.

Model otrzymywał krótki opis każdego gatunku motyla. Na podstawie takiego opisu model miał przypisać gatunek do jednej z trzech klas:

- spadek liczebności,
- stabilna liczebność,
- wzrost liczebności.

Oznacza to, że model nie tworzył własnego tekstu, tylko wybierał jedną z trzech możliwych odpowiedzi.

Dane zostały podzielone na dwie części. Pierwsza część, czyli 80% danych, została wykorzystana do uczenia modelu. Druga część, czyli 20% danych, została wykorzystana do sprawdzenia, jak model radzi sobie z przykładami, których wcześniej nie widział.

Model trenowano przez 5 epok. Oznacza to, że model pięć razy przechodził przez dane treningowe i za każdym razem poprawiał swoje działanie. Dane były przetwarzane partiami po 8 przykładów, dzięki czemu komputer nie musiał analizować wszystkich danych naraz. Podczas treningu zastosowano małe tempo uczenia, aby model stopniowo dostosowywał się do nowego zadania. Użyto także parametru weight decay, który pomaga ograniczać sytuację, w której model zbyt mocno zapamiętuje dane treningowe zamiast uczyć się ogólnej zasady.

W trakcie treningu sprawdzano trzy główne wartości: stratę walidacyjną, accuracy oraz macro F1-score. Strata walidacyjna pokazuje, jak duży błąd popełnia model. Accuracy informuje, jaki procent przykładów został sklasyfikowany poprawnie. Macro F1-score pozwala sprawdzić, czy model radzi sobie dobrze ze wszystkimi klasami, a nie tylko z tą, która pojawia się najczęściej.

8. Wyniki treningu

Wyniki po kolejnych epokach wyglądały następująco:

Epoch	Training Loss	Validation Loss	Accuracy	F1 Macro
1	No log	0.668717	0.606061	0.251572
2	No log	0.512449	0.787879	0.539683
3	No log	0.400768	0.818182	0.566667
4	No log	0.341353	0.818182	0.566667
5	No log	0.312839	0.818182	0.566667

Strata walidacyjna systematycznie spadała, co oznacza, że model poprawiał swoje dopasowanie do danych. Accuracy osiągnęło wartość około 81,8%, jednak macro F1-score wyniósł tylko około 0,57. Oznacza to, że model nie radził sobie jednakowo dobrze ze wszystkimi klasami.

9. Szczegółowa ewaluacja modelu

Po zakończeniu treningu model został oceniony na zbiorze testowym. Wyniki klasyfikacji były następujące:

Klasa	Precision	Recall	F1-score	Support
decreasing	0.54	1.00	0.70	7
stable	1.00	1.00	1.00	20
increasing	0.00	0.00	0.00	6

Ogólna accuracy modelu wyniosła 0.82, czyli około 82%. Jednak dokładniejsza analiza pokazuje, że wynik ten jest częściowo mylący.

Model bardzo dobrze poradził sobie z klasą stable, ponieważ wszystkie 20 przykładów tej klasy zostało sklasyfikowanych poprawnie. Wszystkie 7 przykładów klasy decreasing również zostało rozpoznanych poprawnie. Problem pojawił się przy klasie increasing. Model nie rozpoznał żadnego przykładu tej klasy.

Macierz pomyłek wyglądała następująco:

Rzeczywista klasa	Przewidziane: decreasing	Przewidziane: stable	Przewidziane: increasing
decreasing	7	0	0
stable	0	20	0
increasing	6	0	0

Z macierzy wynika, że wszystkie 6 przykładów klasy increasing zostało błędnie sklasyfikowanych jako decreasing.

10. Interpretacja wyników

Model osiągnął stosunkowo wysoką accuracy, ale nie oznacza to, że działa dobrze dla wszystkich klas. Accuracy wyniosło 81,8%, ponieważ większość przykładów w zbiorze testowym należała do klasy stable, którą model rozpoznał bezbłędnie.

Lepszą miarą jakości w tym przypadku jest macro F1-score, ponieważ traktuje każdą klasę jako równie ważną. Wynik macro F1 wyniósł 0,57, co wskazuje na nierówną skuteczność modelu.

Największy problem dotyczył klasy increasing. Model ani razu nie przewidział tej klasy. Oznacza to, że mimo dobrego wyniku accuracy model nie nauczył się poprawnie rozpoznawać przypadków wzrostu liczebności.

11. Ograniczenia projektu

Projekt pokazuje działanie pełnego procesu uczenia modelu klasyfikacyjnego, ale ma kilka ograniczeń.

Po pierwsze, etykiety zostały utworzone bezpośrednio na podstawie procentowej zmiany liczebności. Oznacza to, że model w praktyce uczy się odtwarzać wcześniej zdefiniowaną regułę, a nie odkrywa samodzielnie złożonych zależności ekologicznych.

Po drugie, dane zostały zamienione na tekst, aby można było użyć modelu DistilBERT. W tym przypadku jest to ciekawe jako demonstracja klasyfikacji tekstu, ale z punktu widzenia samego problemu prostszy model oparty na danych liczbowych mógłby być bardziej naturalnym rozwiązaniem.

Po trzecie, zbiór danych po agregacji był mały. Model był trenowany na niewielkiej liczbie przykładów, co ogranicza jego zdolność generalizacji.

Po czwarte, klasy były niezbalansowane. Najwięcej było przykładów klasy stable, a najmniej przykładów klasy increasing. To prawdopodobnie wpłynęło na fakt, że model nie nauczył się poprawnie rozpoznawać klasy wzrostowej.

12. Wnioski

W projekcie udało się przygotować kompletny pipeline uczenia maszynowego: od pobrania danych, przez ich przetworzenie, utworzenie etykiet, tokenizację tekstu, trening modelu DistilBERT, aż po ewaluację wyników.

Model osiągnął accuracy na poziomie około 81,8%, jednak szczegółowa analiza wykazała, że wynik ten nie oddaje w pełni jakości modelu. Model bardzo dobrze rozpoznawał klasę stable, poprawnie rozpoznał przykłady klasy decreasing, ale całkowicie nie poradził sobie z klasą increasing.

Najważniejszy wniosek jest taki, że sama accuracy nie wystarcza do oceny modelu, szczególnie gdy dane są niezbalansowane. W tym przypadku bardziej informacyjny był macro F1-score oraz macierz pomyłek, które pokazały rzeczywisty problem z rozpoznawaniem jednej z klas.

Projekt można uznać za poprawną demonstrację zastosowania modelu językowego do klasyfikacji trendu populacji, ale nie jako w pełni wiarygodny model ekologiczny. Aby poprawić jakość modelu, należałoby zwiększyć liczbę danych, lepiej zbalansować klasy lub zastosować prostszy model klasyfikacyjny oparty bezpośrednio na cechach liczbowych.

13. Link do repozytorium GitHub

Repozytorium projektu znajduje się pod adresem:

[Repozytorium GitHub projektu](#)

14. Podział pracy / wkład członków grupy

Projekt został wykonany wspólnie przez członków grupy.

Zakres prac obejmował:

- weryfikację projektu,
- wybór modelu,
- pracę nad programem,
- wykonanie analizy danych,
- przygotowanie wizualizacji,
- opracowanie raportu końcowego.

Każdy członek grupy uczestniczył w realizacji projektu w równym stopniu.